

Matriz de Costos

Justificación del modelo de IA elegido

Para este proceso (identificar el nombre de un producto a partir de un mensaje corto de WhatsApp/Telegram) se usa **OpenAI GPT-4o-mini**, en vez de un modelo más grande como GPT-4o o Claude Sonnet. La razón es que la tarea es simple y acotada — extraer una palabra clave de un texto corto —, no requiere razonamiento profundo ni lectura de documentos extensos, por lo que un modelo "mini" da resultados igual de precisos a una fracción del costo.

Tarea	Modelo recomendado	Por qué
Identificar producto en un mensaje corto (este proyecto)	GPT-4o-mini	Tarea simple, mensajes cortos, no necesita razonamiento profundo — abarata mucho el costo por consulta
Análisis de sentimiento en reclamos largos o contratos	Claude Sonnet	Mejor comprensión de contexto extenso y matices de lenguaje natural
Procesamiento de cientos de consultas acumuladas, sin urgencia	Batch API (de cualquiera de los dos)	50% de descuento por no requerir respuesta en tiempo real

Cálculo de costo estimado

Supongamos que el bot recibe **300 consultas por mes**:

Concepto	Valor
Tokens de entrada por consulta (prompt + mensaje)	~150 tokens
Tokens de salida por consulta (respuesta corta)	~10 tokens
Precio GPT-4o-mini (referencia)	\$0.15 / millón tokens entrada — \$0.60 / millón tokens salida

Costo mensual con GPT-4o-mini:

- Entrada: $300 \times 150 = 45.000$ tokens $\rightarrow$ \$0.0068
- Salida: $300 \times 10 = 3.000$ tokens $\rightarrow$ \$0.0018
- **Total: $\approx$ \$0.009 por mes** (menos de un centavo)

Si se usara un modelo más grande (ej. GPT-4o, ~10 veces más caro):

- Total estimado: $\approx$ \$0.09 por mes

Ahorro: usar el modelo "mini" para esta tarea simple representa un ahorro de aproximadamente **90%** respecto a usar un modelo grande, sin pérdida de precisión porque la tarea no lo requiere.

